**МИНОБРНАУКИ РОССИИ**
**САНКТ-ПЕТЕРБУРГСКИЙ ГОСУДАРСТВЕННЫЙ**
**ЭЛЕКТРОТЕХНИЧЕСКИЙ УНИВЕРСИТЕТ**
**«ЛЭТИ» ИМ. В.И. УЛЬЯНОВА (ЛЕНИНА)**
**Кафедра МОЭВМ**

# ОТЧЕТ

**по лабораторной работе №3**

**по дисциплине «Искусственные нейронные сети»**

**Тема: «Регрессионная модель изменения цен на дома в Бостоне»**

Студент гр. 7381 _____ Вологдин М.Д.

Преподаватель _____ Жукова Н.А.

Санкт-Петербург

2020

**Цель работы.**

Реализовать предсказание медианной цены на дома в пригороде Бостона в середине 1970-х по таким данным, как уровень преступности, ставка местного имущественного налога и т.д.

Данный набор содержит относительно немного образцов данных: всего 506, разбитых на 404 обучающих и 102 контрольных образца. И каждый признак во входных данных (например, уровень преступности) имеет свой масштаб. Например, некоторые признаки являются пропорциями и имеют значения между 0 и 1, другие — между 1 и 12 и т. д.

**Порядок выполнения работы.**

- Ознакомиться с задачей регрессии
- Изучить отличие задачи регрессии от задачи классификации
- Создать модель
- Настроить параметры обучения
- Обучить и оценить модели
- Ознакомиться с перекрестной проверкой

**Требования.**

1. Объяснить различия задач классификации и регрессии
2. Изучить влияние кол-ва эпох на результат обучения модели
3. Выявить точку переобучения
4. Применить перекрестную проверку по K блокам при различных K
5. Построить графики ошибки и точности во время обучения для моделей, а также усредненные графики по всем моделям

**Ход работы.**

Задача классификации сводится к определению класса объекта по его характеристикам. Необходимо заметить, что в этой задаче множество классов, к которым может быть отнесен объект, заранее известно.

Задача регрессии, подобно задаче классификации, позволяет определить по известным характеристикам объекта значение некоторого его параметра. В отличие от задачи классификации значением параметра является не конечное множество классов, а множество действительных чисел.

Посмотрим на результаты нейронной сети на данных по умолчанию – на 4 блоках и 100 эпохах. Графики представлены на рис. 1, 2.

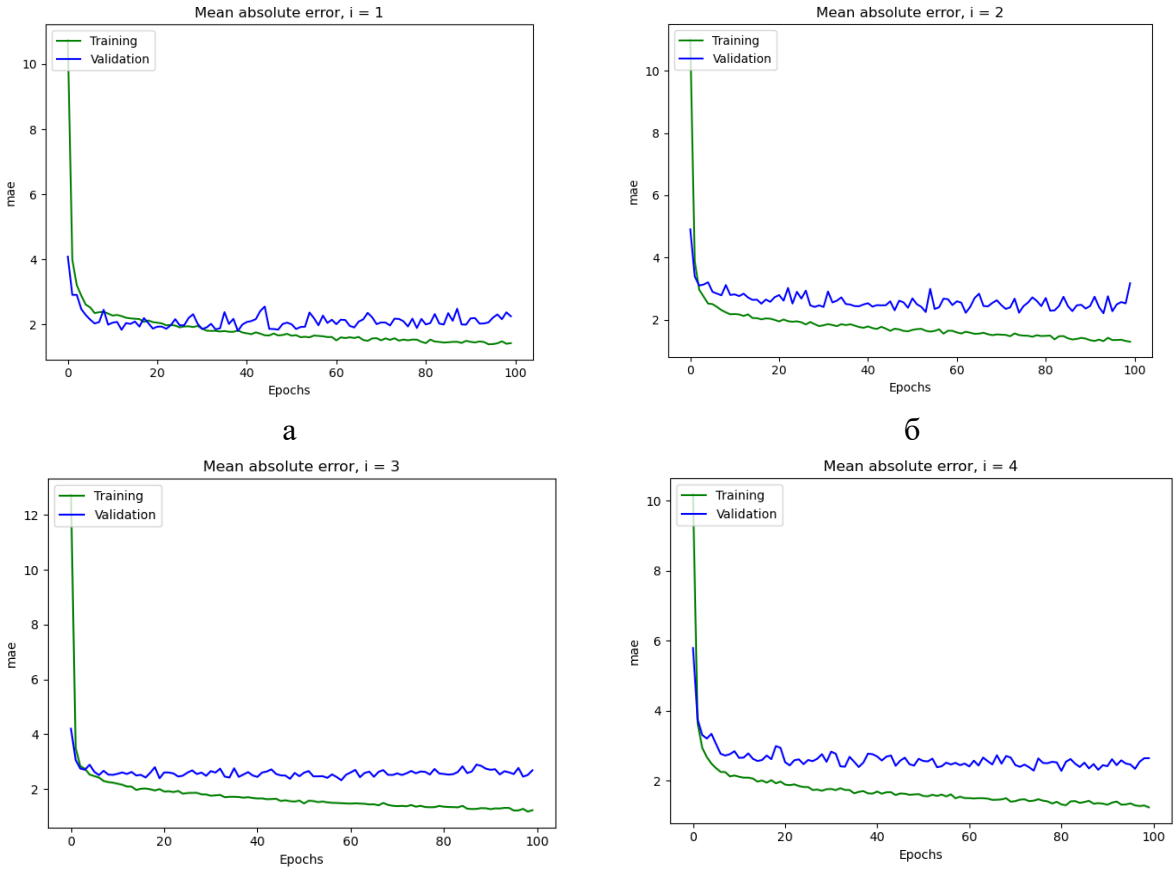


а б в г

Рисунок 1 – График оценки MAE для блока а–1, б–2, в–3, г–4.

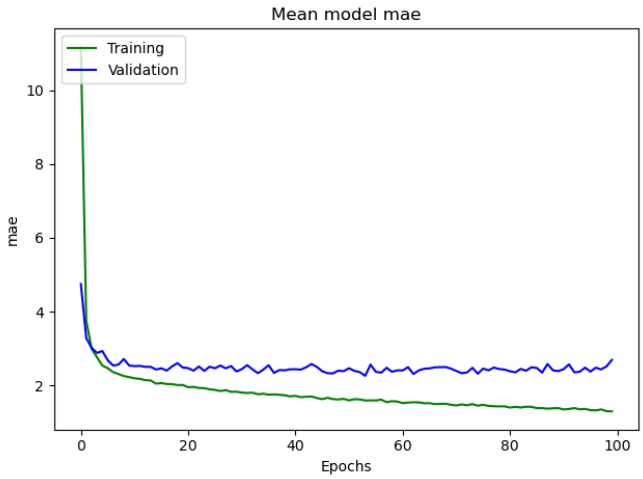


Рисунок 2 – График среднего значения MAE

Заметим, что оценки MAE на тестовых данных начинают возрастать после ~18 эпохи, значит следует убавить количество эпох до этого значения во избежание переобучения.

Рассмотрим модели с 18 эпохами на 2, 4, 6 и 8 блоках. Графики представлены на рис. 3.

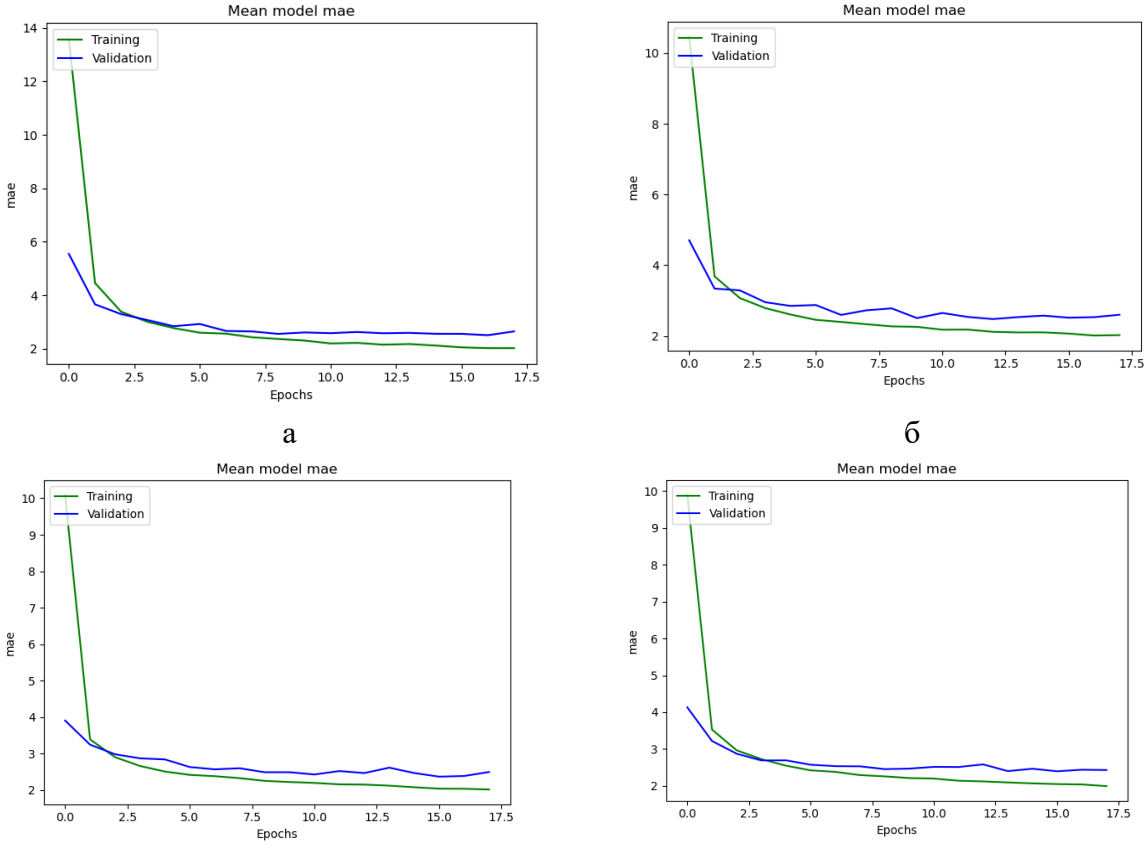


Рисунок 3 – Графики среднего значения MAE для модели с количеством блоков: а–2, б–4, в–6, г–8.

Из графиков видим, что наилучшей сходимостью и наименьшей средней ошибкой обладает модель с 6 блоками.

**Выводы.**

В ходе выполнения данной работы была изучена задача регрессии и ее отличие от задачи классификации с помощью библиотеки Keras. Также было изучено влияние количества эпох и числа блоков на результат обучения сети.

# ПРИЛОЖЕНИЕ А

# ИСХОДНЫЙ КОД

```
import numpy as np
from tensorflow.keras.layers import Dense
from tensorflow.keras.models import Sequential
from tensorflow.keras.datasets import boston_housing
import matplotlib.pyplot as plt


def build_model():
    model1 = Sequential()
    model1.add(Dense(64, activation='relu',
input_shape=(train_data.shape[1],)))
    model1.add(Dense(64, activation='relu'))
    model1.add(Dense(1))
    model1.compile(optimizer='rmsprop', loss='mse',
metrics=['mae'])
    return model1


(train_data, train_targets), (test_data, test_targets) =
boston_housing.load_data()

mean = train_data.mean(axis=0)
train_data -= mean
std = train_data.std(axis=0)
train_data /= std

test_data -= mean
test_data /= std

k = 6
num_val_samples = len(train_data) // k
num_epochs = 18
all_scores = []

mean_loss = []
mean_mae = []
mean_val_loss = []
mean_val_mae = []

for i in range(k):
```

```
        print('processing fold #', i)
        val_data = train_data[i * num_val_samples: (i + 1) *
num_val_samples]
        val_targets = train_targets[i * num_val_samples: (i + 1) *
num_val_samples]
        partial_train_data = np.concatenate([train_data[:i *
num_val_samples], train_data[(i + 1) * num_val_samples:]],
                                            axis=0)
        partial_train_targets = np.concatenate(
            [train_targets[:i * num_val_samples], train_targets[(i +
1) * num_val_samples:]], axis=0)
        model = build_model()
        history = model.fit(partial_train_data,
partial_train_targets, epochs=num_epochs, batch_size=1,
                            validation_data=(val_data, val_targets),
verbose=0)

mean_val_mae.append(history.history['val_mean_absolute_error'])
        mean_mae.append(history.history['mean_absolute_error'])
        plt.plot(history.history['mean_absolute_error'], 'g')
        plt.plot(history.history['val_mean_absolute_error'], 'b')
        plt.title('Mean absolute error' + ', i = ' + str(i + 1))
        plt.ylabel('mae')
        plt.xlabel('Epochs')
        plt.legend(['Training', 'Validation'], loc='upper left')
        plt.show()

        mean_val_loss.append(history.history['val_loss'])
        mean_loss.append(history.history['loss'])

        plt.plot(history.history['loss'], 'g')
        plt.plot(history.history['val_loss'], 'b')
        plt.title('Model loss' + ', i = ' + str(i + 1))
        plt.ylabel('loss')
        plt.xlabel('Epochs')
        plt.legend(['Training', 'Validation'], loc='upper left')
        plt.show()

    plt.plot(np.mean(mean_mae, axis=0), 'g')
    plt.plot(np.mean(mean_val_mae, axis=0), 'b')
    plt.title('Mean model mae')
    plt.ylabel('mae')
    plt.xlabel('Epochs')
    plt.legend(['Training', 'Validation'], loc='upper left')
    plt.show()
```

```
plt.plot(np.mean(mean_loss, axis=0), 'g')
plt.plot(np.mean(mean_val_loss, axis=0), 'b')
plt.title('Mean model loss')
plt.ylabel('loss')
plt.xlabel('Epochs')
plt.legend(['Training', 'Validation'], loc='upper left')
plt.show()
```